

项目：城市餐饮商家数据分析与评分预测Web平台

针对该项目，调研杭州餐饮数据来源，可以从哪里获取数据，需要获取哪些数据

🧠 已思考（用时 3 秒） >

针对“城市餐饮商家数据分析与评分预测Web平台”项目，杭州的餐饮数据可以从**政府开放平台、商业平台、学术与竞赛平台**等多个渠道获取。以下是具体的数据来源和需要获取的数据字段建议。

📖 一、数据来源渠道

1. 政府官方开放数据（权威、可靠）

- **杭州市数据开放平台** (data.hangzhou.gov.cn)：杭州市官方的数据开放平台 ³²，提供市场监管、文旅、地理信息等数据集 ³²。你需要注册账号并申请，数据格式支持JSON、CSV等 ³²。
- **杭州文化和旅游数据在线** (data.wgly.hangzhou.gov.cn)：专注文旅数据的开放平台 ⁵，提供商圈、客流、消费等实时数据 ⁵。**无需注册登录即可免费查询** ⁵。
- **具体数据集案例：**
 - **杭州“三小”备案信息**：由杭州市市场监督管理局发布，包含小作坊、小餐饮、小食杂店的备案信息（主体名称、经营范围等），约308条记录 ⁴。
 - **行政区划数据**：提供杭州市行政区划名称、边界、中心点经纬度等数据 ^{1 2}。

2. 商业平台与API（数据丰富、实时）

- **高德地图API**：可获取餐饮商家的POI（兴趣点）信息，如名称、地址、经纬度、电话等 ⁹。有开发者将探店UP主的数据与高德地图结合，生成了结构化的店铺数据。
- **大众点评**：平台本身有丰富的餐厅评分、评价、价格等信息 ⁹。可通过其网页(dianping.com/hangzhou) ⁹ 或开源爬虫项目 ⁹ 获取数据，但需注意平台反爬机制。
- **美团**：有公开的杭州美食团购数据 ⁹，可通过爬虫获取 ⁹。此外，美团也与政府合作，提供商圈概况、客流热力等分析数据 ⁹。
- **饿了么开放平台**：提供官方API ⁹，可查询餐厅、获取分类列表等 ⁹。但部分接口（如城市榜单）可能已下线，且部分数据需商家授权 ⁹。

3. 学术研究、竞赛与开源社区

- **阿里云DataV Atlas**: 提供 `hangzhou_poi_sample` 样例数据, 包含杭州餐饮娱乐店的分类、位置和评价等信息 [🔗](#) [1](#) [2](#)。
- **阿里云天池**: 提供O2O、商家客流量预测等脱敏数据集 [🔗](#), 可用于模型训练 [🔗](#)。
- **GitHub等开源社区**: 有开发者分享的杭州餐饮数据爬虫项目 [🔗](#) 或已整理的结构化数据集 [🔗](#)。
- **学术论文**: 知网(CNKI)等平台上有基于大众点评数据研究杭州餐饮空间分布的论文, 可参考其数据来源与研究方法 [🔗](#)。

二、需要获取的核心数据字段

数据类别	核心字段	用途示例
商家基础信息	商家ID、名称、地址、经纬度、联系电话	在地图上定位、展示商家基本信息
商家分类信息	一级分类 (如: 美食)、二级分类 (如: 杭帮菜、火锅) 2	进行市场细分、分析不同品类餐饮的分布与热度
消费者评价数据	总体评分、细分评分 (口味、环境、服务) 23 、 评论内容	计算商家的综合得分, 进行情感分析, 作为评分预测模型的关键特征
交易与价格数据	人均消费、团购价格、优惠券信息 🔗	分析商家的定价策略和性价比, 作为评分预测的特征
运营数据	营业时间 23 、 推荐菜 🔗	分析商家的运营规律, 挖掘菜品特色
时空与地理数据	所在行政区、所属商圈 5 、 与CBD/交通枢纽的距离	进行地理空间分析, 探究地理位置对商家评分和客流的影响
宏观与客流数据	商圈客流画像 (日均到访人口、年龄等) 5 、 周边设施 (地铁、公交) 5	评估商圈的商业潜力和竞争环境, 为评分预测提供宏观背景

三、注意事项

- **数据合规性**: 使用爬虫技术时, 务必遵守平台的 `robots.txt` 协议和相关法律法规, 避免对目标网站造成过大压力。使用官方API是最合规的方式 [🔗](#)。
- **数据质量**: 政府开放数据更新周期可能较长 (如“三小”数据为每年更新 [🔗](#)), 而商业平台数据实时性更好。需根据分析目标权衡。

- **数据整合**：你的平台最终可能需要融合多个来源的数据，这要求对不同数据源的字段进行清洗、对齐和整合，构建统一的数据模型。

本回答由 AI 生成，内容仅供参考，请仔细甄别

 54 个网页

如何运用python大数据挖掘技术构建数据爬取模型，爬取杭州中心城区餐饮点数据

 已思考（用时 3 秒） >

针对“爬取杭州中心城区餐饮点数据”的目标，我为你梳理了一套可行的技术方案。核心思路是**组合使用“高德地图API”获取基础POI数据和“大众点评等平台”获取详细的评分、评论信息。**

方案一：高德地图API（推荐首选）

这是获取餐饮商家基础信息最合规、高效的方式  26 。

- **数据特点**：数据格式规范（JSON），包含商家名称、地址、经纬度、电话、营业时间等核心字段 ²⁶，且更新及时。
- **技术实现**：调用高德 `/v3/place/text`（文本搜索）或 `/v3/place/polygon`（多边形搜索）API  ²⁶。可通过Python的 `requests` 库发送HTTP请求获取数据  ²⁶。
- **关键代码示例**：

python

```
import requests
import time
import pandas as pd
```

```
class AMapCateringCrawler:
    def __init__(self, api_key):
        self.api_key = api_key
        self.base_url = "https://restapi.amap.com/v3/place/text"
        self.types = "050000" # 高德POI分类：餐饮服务[reference:7][reference:8]

    def fetch_pois(self, city="杭州", keywords="美食", page=1, page_size=25):
        params = {
            "key": self.api_key,
            "keywords": keywords,
            "types": self.types,
            "city": city,
```

```

        "offset": page_size,
        "page": page,
        "extensions": "all" # 获取更详细信息
    }
    try:
        response = requests.get(self.base_url, params=params, timeout=10)
        data = response.json()
        if data.get("status") == "1":
            return data.get("pois", [])
        else:
            print(f"API Error: {data.get('info')}")
            return []
    except Exception as e:
        print(f"Request failed: {e}")
        return []

def collect(self, city="杭州", max_pages=10):
    all_pois = []
    for page in range(1, max_pages + 1):
        print(f"正在采集第 {page} 页...")
        pois = self.fetch_pois(city, page=page)
        if not pois:
            break
        all_pois.extend(pois)
        time.sleep(0.35) # 控制请求频率, 避免超限
    return all_pois

# 使用示例
crawler = AMapCateringCrawler(api_key="YOUR_AMAP_API_KEY")
pois_data = crawler.collect(city="杭州市", max_pages=10)
df = pd.DataFrame(pois_data)
df.to_csv("hangzhou_catering_raw.csv", index=False, encoding="utf-8-sig")
print(f"采集完成, 共 {len(df)} 条记录")

```

注意：高德API免费版有每日调用量和并发限制²⁶。如需大规模采集，可考虑使用基于“四叉树算法”的开源工具 `GaoDe-poi-crawler` 来突破单次API返回的数据量限制²⁷。

方案二：大众点评等平台爬虫

此方法能获取到更详细的店铺信息，如**用户评论**、**口味/环境/服务细分评分**等²⁸。

- **技术挑战：**这些平台**反爬机制非常严格**²⁹，常使用**动态字体加密**³⁰、**CSS偏移**³¹等技术。
- **应对策略：**

- **模拟浏览器**：使用 **Selenium** 或 **Playwright** 模拟真实用户行为 [🔗]。当遇到验证码时，可暂停程序手动通过。
- **直接调用API**：高级方案是使用 **Playwright** 拦截网络请求，直接捕获平台后端API返回的JSON数据，更稳定高效 [🔗]。
- **使用代理IP和Cookie池**：轮换IP和Cookie，降低被封禁的风险 [🔗]。
- **开源项目参考**：
 - `dianping_crawler`：基于Playwright，支持多城市、关键词搜索和评论抓取。
 - `dianping_spider`：功能强大，解决了动态字体加密问题，支持IP代理和Cookie池 [🔗]。
 - `spider_DianPing`：基于Selenium的轻量级示例程序，适合入门参考 [🔗]。

🔪 三、数据处理与质量管理

无论从哪种渠道获取数据，都需要进行后续处理：

1. **数据清洗**：使用Pandas处理缺失值、格式化字段（如将营业时间统一为标准格式）、去除重复记录。
2. **数据字典**：为每个字段（如 `name`、`address`、`avg_score`）建立统一的描述和格式规范。
3. **质量评估**：定期统计数据的**总量**、**字段缺失率**、**重复率**等指标，确保数据质量。

💎 总结与建议

针对你的项目，我建议采用**混合策略**：

1. **以高德地图API为主**：快速、合规地获取杭州中心城区餐饮商家的**基础地理信息**（名称、地址、坐标等），建立初始数据集。
2. **以平台爬虫为辅**：针对高德数据中的核心商家，再使用爬虫技术从大众点评等平台补充**详细的评分、评论等深度信息**。
3. **数据整合**：将两部分数据通过商家名称、地址等字段进行关联和融合，形成最终的分析数据集。

另外，作为补充，也可以关注 **杭州市数据开放平台** 等政府开放数据，获取权威的备案信息作为参考。

你目前的Python基础怎么样？如果准备好了，我们可以先从高德地图API的接入开始写起。

本回答由 AI 生成，内容仅供参考，请仔细甄别



hangzhou_catering_raw...
CSV 85.7KB

输出结果如表格所示，是否符合项目要求

🔗 已思考 (用时 5 秒) >

好的，我们来一起看看你采集到的这份数据。我会从**数据完整性**、**字段匹配度**、**数据质量**三个方面，结合项目的“评分预测”目标，来分析它是否符合要求，并给出后续建议。

一、数据概览与优点

数据来源：很明显，这份数据来自高德地图的POI（兴趣点）接口，包含了杭州多个商圈（来福士、万象城、天虹等）的餐饮商家信息。

优点：

- **字段丰富：**包含了 id、name、address、location（经纬度）、adname（行政区）、type（分类）、tel（电话）、atag（标签）等基础信息，这些是很好的**基础数据**。
- **地理信息准确：**有精确的经纬度，适合做空间分布分析。
- **覆盖范围：**数据覆盖了上城区、萧山区、滨江区等，基本符合“杭州中心城区”的要求。
- **数据量：**从文件看有约200+条记录，作为初期样本是够的。

二、关键缺陷与项目要求差距

⚠️ **最大的问题：**数据缺少**评分和价格字段**，而这两个字段恰好是“评分预测”项目的核心。

项目需求字段	本数据集中是否有？	说明
avg_score（综合评分）	❌ 无	只有 featured_reviews（精选评论），但没有评分数字。
taste_score / environment_score / service_score	❌ 无	高德基础数据不提供细分评分。
avg_price（人均消费）	❌ 无	biz_ext 字段为空，未获取到。

项目需求字段	本数据集中是否有？	说明
comment_count （评论数）	✗ 无	高德不提供该字段。
recommend_dishes （推荐菜）	✗ 无	atag 可能有少量标签，但不是结构化数据。

这意味着：如果直接使用这份数据，**无法训练任何评分预测模型**，因为缺少目标变量（评分）和关键特征（价格、评论数等）。

三、其他数据质量问题

- 1. **字段空值率高：** biz_ext 、 photos 、 shopinfo 、 featured_reviews_remake 等字段几乎全为空，造成大量缺失。
- 2. **重复数据：** 部分 id 重复（如 B0FFH2VWTH 出现多次），可能因为同一商家在不同分类下重复，需去重。
- 3. **分类不统一：** type 字段既有“中餐厅;火锅店”又有“餐饮服务;快餐厅;肯德基”，解析较复杂。
- 4. **数据时效性：** 未标明采集日期，但高德数据一般较新，可以接受。

四、是否符合项目要求？

直接使用： ✗ 不符合。缺少评分和价格，无法完成“评分预测”任务。

作为基础数据： ✔ 部分符合。可以作为商家的地理位置、名称、分类等基准信息，在此基础上**补充其他数据源**（如大众点评的评分、价格、评论数），然后进行融合。

五、后续改进建议

1. 补充评分和价格数据

- 使用采集到的 name 和 address ，通过**大众点评爬虫**或**美团API**获取每个商家的评分、人均消费、评论数等字段。
- 或者利用高德地图的**搜索详情API**（ /v3/place/detail ），传入 id ，可以获取更详细的 biz_ext （包含评分和价格），但需要确认高德是否提供这些数据（部分POI有评分）。

2. 数据清洗与整合

- 去重：根据 id 去重，保留一条完整记录。
- 标准化分类：将 type 字段拆分为一级、二级分类，便于分析。
- 处理空值：对于缺失的字段，若后续补充不上，可考虑删除或标记。

3. 扩大采集范围

- 你目前的数据集中在几个大型商场，可以扩展搜索关键词（如“杭帮菜”、“火锅”），并设置分页，覆盖更多街区。

4. 保存原始数据


- 你已经保存了CSV，很好。建议同时记录采集日期、API参数，并保留原始JSON，便于溯源。

六、结论

你采集的这份数据是**良好的起点**，但**不足以支撑评分预测模型**。下一步需要：

1. **确定评分数据来源**（大众点评、美团、高德详情API）。
2. **编写补充采集程序**，获取每个商家的评分、价格、评论数。
3. **合并两个数据集**，形成完整的分析表格。

如果你需要，我可以帮你设计一个“基于商家名称和地址”去匹配大众点评评分的小型爬虫框架，或者教你如何调用高德详情API来获取更完整的信息。你希望先走哪条路呢？



输出表格是否符合项目要求

已思考（用时 4 秒） >

这份**增强后的数据**已经具备了项目所需的**核心要素——评分和价格**，这标志着你的数据采集工作取得了关键进展！ 🎉

整体来看，数据**已基本满足评分预测项目的基础要求**，可以进入建模准备阶段。以下是对这份数据的详细评估和改进建议：

一、数据现状评估（符合项目要求的部分）

评估维度	状态	说明
目标变量（评分）	✅ 已具备	rating 字段已补充，覆盖大部分商家，评分范围在4.3~4.9之间
核心特征（价格）	✅ 已具备	cost 字段已补充，覆盖大部分商家，可作为重要特征
地理位置	✅ 完整	location 包含精确经纬度
商家分类	✅ 完整	type 和 atag 提供了丰富的分类标签
商家名称与地址	✅ 完整	可用于后续匹配或展示

二、仍存在的不足与改进空间

1. 少量缺失仍需处理

- 缺失情况：
 - cost 字段有少量空值（显示为 []），如“觅隐·千寻”、“七欣天”、“粤江南”等
 - rating 字段在少数记录中为空
- 解决方案：
 - 若商家数量不多，可手工补充或标记为 -1
 - 对于建模，可直接删除这些记录（缺失占比<5%时影响可控）

2. 数据重复问题

- 重复记录：部分商家（如“炉鱼(杭州天虹购物中心店)”）出现两次，id 相同
- 解决方案：按 id 去重，保留一条记录

3. 分类字段需解析

- type 字段包含多级分类，如 "餐饮服务;中餐厅;火锅店"
- **建议：**拆分为 category_l1 、 category_l2 、 category_l3 三列，便于分类分析

4. 价格字段格式问题

- cost 的值如 87.00 、 487.00 是字符串格式，需要转为 float
- **建议：**读取时指定 dtype 或清洗时转换

5. 数据分布相对集中

- 当前数据主要集中在来福士、万象城、天虹等大型商场
- **建议：**后续采集可扩展到更多商圈和街道，增加样本多样性

三、下一步具体操作建议

步骤1：数据清洗

python

```
import pandas as pd
import numpy as np
```

读取数据

```
df = pd.read_csv("hangzhou_catering_enhanced.csv", encoding="utf-8-sig")
```

1. 按id去重

```
df = df.drop_duplicates(subset=['id'], keep='first')
```

2. 处理缺失值

```
df['rating'] = pd.to_numeric(df['rating'], errors='coerce')
```

```
df['cost'] = pd.to_numeric(df['cost'], errors='coerce')
```

```
df_clean = df.dropna(subset=['rating', 'cost']) # 删除评分或价格为空的记录
```

3. 拆分分类

```
df_clean['category_l1'] = df_clean['type'].str.split(';').str[0]
```

```
df_clean['category_l2'] = df_clean['type'].str.split(';').str[1]
```

```
df_clean['category_l3'] = df_clean['type'].str.split(';').str[2]
```

```
# 4. 拆分经纬度
df_clean['longitude'] = df_clean['location'].str.split(',').str[0].astype(float)
df_clean['latitude'] = df_clean['location'].str.split(',').str[1].astype(float)

# 5. 保存清洗后的数据
df_clean.to_csv("hangzhou_catering_cleaned.csv", index=False, encoding="utf-8-sig")
print(f"清洗完成, 剩余 {len(df_clean)} 条有效记录")
```

步骤2：探索性数据分析（EDA）

python

```
import matplotlib.pyplot as plt
import seaborn as sns

# 评分分布
plt.figure(figsize=(10,4))
plt.subplot(1,2,1)
df_clean['rating'].hist(bins=20, edgecolor='black')
plt.title('评分分布')
plt.xlabel('评分')

# 价格分布
plt.subplot(1,2,2)
df_clean['cost'].hist(bins=30, edgecolor='black')
plt.title('人均消费分布')
plt.xlabel('价格(元)')
plt.tight_layout()
plt.show()

# 评分与价格的关系
plt.figure(figsize=(8,6))
sns.scatterplot(data=df_clean, x='cost', y='rating', alpha=0.6)
plt.title('评分 vs 人均消费')
plt.xlabel('人均消费(元)')
plt.ylabel('评分')
plt.show()
```

步骤3：特征工程准备

特征类型	建议使用的字段	说明
数值特征	cost , rating （作为目标变量）	可直接使用

特征类型	建议使用的字段	说明
分类特征	category_l1 , category_l2 , adname	进行One-Hot或Label Encoding
地理特征	longitude , latitude	可聚类或计算与市中心距离
文本特征	atag （标签）	可提取关键词或标签数量
时间特征	collect_date	采集时间（若后续有更新）

四、建模可行性分析

以当前数据（约300+条记录）来看：

- ✅ **可以进行初步建模**：使用线性回归、决策树、随机森林等
- ⚠️ **数据量稍小**：深度学习或复杂模型可能效果不佳
- 💡 **建议**：继续采集数据，目标至少1000~2000条，模型效果会更稳定

五、下一阶段采集建议

- 扩大商圈覆盖**：西湖景区、武林广场、黄龙商圈等
- 增加品类多样性**：目前火锅、江浙菜偏多，可增加咖啡、烘焙、日料等
- 尝试多关键词搜索**：如“杭帮菜”、“川菜”、“日料”等分别采集
- 采集评论数**：高德API可能不提供，可考虑大众点评补充

六、总结

维度	评估结果
数据完整性	★★★★ (大部分商家有评分和价格)
数据质量	★★★★ (少量缺失和重复，清洗后可用)
建模可行性	★★★★ (可用于回归/分类模型初步训练)

继续采集必要性

✅ 建议继续扩展数据量

结论：这份数据已经**可以支撑评分预测模型的初步构建**。建议先进行数据清洗和简单建模，验证模型效果，同时继续扩展数据采集范围，为后续模型优化做准备。

需要我帮你写一个完整的评分预测模型训练脚本吗？或者继续扩展数据采集范围？

如何继续采集数据，增加数据量

🗒️ 已思考（用时 4 秒） >

继续增加数据量，核心思路是**扩展采集的“广度”和“深度”**。“广度”指覆盖更多区域和品类，“深度”指获取更丰富的字段。以下是几个具体可行的方案。

 方案一：深耕高德API，精细化扩展数据

这是最直接、合规的方式，可以基于你已有的代码进行扩展。

1. 多关键词组合搜索

目前你可能只用了一个通用关键词。可以通过组合多个关键词来覆盖不同品类的商家🔗。

- **具体做法：**维护一个关键词列表，如 ["杭帮菜", "火锅", "日料", "咖啡", "奶茶", "烧烤"]，然后遍历这些关键词进行搜索🔗 1。
- **代码示例：**

```
python

keywords = ["杭帮菜", "火锅", "日料", "咖啡", "奶茶", "烧烤", "川菜", "粤菜"]
all_pois = []
for keyword in keywords:
    print(f"正在搜索关键词: {keyword}")
    # 调用你已有的 fetch_pois 函数，传入 keyword
    pois = fetch_pois(city="杭州市", keywords=keyword, page=1)
    all_pois.extend(pois)
    time.sleep(0.5) # 控制请求频率
```

2. 分区域（行政区/多边形）采集

你的数据目前集中在几个商场，可以按**行政区**或自定义的**地理网格**来采集，确保覆盖全市🔗。

- **按行政区**：获取杭州所有区（如上城区、西湖区、拱墅区等）的名称，然后针对每个区进行搜索。
- **按矩形/多边形网格**：将杭州地图划分为多个小矩形，然后对每个矩形区域进行搜索 [🔗](#)。这种方法能有效突破单次API返回200条记录的限制。
- **高级工具**：可以关注GitHub上的开源项目，如 `GaoDe-poi-crawler`，它实现了“四叉树递归拆分算法”，能自动将大区域拆分，从而获取该区域内的**全部**POI数据。

3. 扩展POI分类 (typecode)

目前你可能使用的是 `050000`（餐饮服务）这个大分类。可以细化到二级甚至三级分类，获取更垂直的数据 [🔗](#)。

- **具体做法**：从高德官方下载《POI分类编码表》 [🔗](#)，选择你感兴趣的细分代码，如 `050100`（中餐厅）、`050200`（外国餐厅）、`050300`（快餐厅）等 [🔗](#)。
- **代码示例**：

```
python

# 在API请求参数中，将 types 参数设置为具体的分类代码
params = {
    "key": YOUR_API_KEY,
    "keywords": "", # 可以不填关键词，仅用类型筛选
    "types": "050100|050200|050300", # 多种类型用 | 分隔[reference:13]
    "city": "杭州市",
    "offset": 25,
    "page": 1
}
```

⚠ 方案二：探索其他数据源（注意合规与风险）

除了高德，还有其他数据源可以获取更丰富的商家信息。

1. 大众点评

大众点评有详细的餐厅评分、评论、推荐菜等数据 [🔗](#)。

- **技术方案**：由于其反爬虫机制严格 [🔗](#)，通常采用 **Playwright** 或 **Selenium** 模拟浏览器操作。
- **开源项目参考**：可以关注GitHub上的 `dianping_crawler` 项目，它实现了多城市、关键词搜索和评论抓取功能 [🔗](#)。

2. 美团

美团数据与大众点评类似，同样有严格的反爬措施 [🔗](#)。

- **技术方案：**可参考其移动端API的逆向分析 [🔗](#)，或使用浏览器自动化工具 [🔗](#)。

3. 其他开放数据

- **DataV Atlas：**其 `hangzhou_poi_sample` 数据集包含杭州餐饮娱乐店的样例数据 [🔗](#)。
- **杭州市数据开放平台：**可查找是否有市场监管局发布的餐饮企业备案信息等公开数据。

方案三：多源数据融合（进阶）

将来自不同渠道的数据进行整合，可以构建一个信息更全面的数据集。

- **核心思路：**以高德API获取的商家 `name` 和 `address` 为“主键” ¹，然后通过编程手段，从大众点评或美团匹配并抓取该商家的**详细评分、评论数、推荐菜**等字段 [🔗](#)。
- **价值：**这种融合能极大地丰富你的特征工程，为后续的评分预测模型提供更多维度的信息。

重要提醒

- **合规第一：**在使用任何爬虫技术前，请务必遵守目标网站的 `robots.txt` 协议和相关法律法规 ¹。
- **控制频率：**为高德API的请求设置合理的延时（如0.3-0.5秒），避免IP被封。
- **数据去重：**采集后务必根据商家 `id` 或 `name+address` 组合进行去重。
- **保存原始数据：**始终保留一份未经修改的原始数据，以便溯源。

总结与建议

建议按以下优先级推进：

1. **首选（高德API扩展）：**先实现**多关键词**和**分区域**采集，这是最安全、高效、合规的方式，能立竿见影地增加数据量。
2. **次选（其他数据源）：**在数据量达到一定规模（如1000-2000条）后，再考虑从大众点评等平台补充深度字段。
3. **进阶（多源融合）：**这是最终目标，能让你的数据集在“广度”和“深度”上都达到最优。

本回答由 AI 生成，内容仅供参考，请仔细甄别



该结果如何

🕒 已思考 (用时 5 秒) >

这份 `hangzhou_catering_combined.csv` 数据结果整体上非常出色，标志着你的数据采集工作已经成功完成，进入了**高质量、可建模**的阶段！🎉

结合项目目标和之前的采集任务，我从以下几个核心维度为你评估这份数据：

一、核心成果评估（符合项目要求的部分）

评估维度	状态	说明
数据量	✅ 显著增加	记录数已从最初的~200条扩展到 2300+条 （估算），完全满足建模需要。
评分覆盖	✅ 完整	几乎每条记录都有 <code>rating</code> 字段，作为目标变量可直接使用。
价格覆盖	✅ 完整	绝大多数记录都有 <code>cost</code> 字段，部分高端餐厅价格偏高达1450元，符合实际情况。
地理信息	✅ 完整	<code>location</code> 经纬度齐全，覆盖杭州多个行政区（上城、萧山、滨江、西湖等）。
分类信息	✅ 丰富	<code>type</code> 字段提供多级分类， <code>atag</code> 提供菜品标签。
商家标签	✅ 有价值	<code>atag</code> 字段包含推荐菜和标签，可作为文本特征。

二、数据特征与亮点

1. 评分分布合理

从数据看，评分范围在**4.3~4.9**之间，分布较为集中。评分**4.5~4.7**的商家居多，高分餐厅（**4.8~4.9**）数量适中，符合真实餐饮评分分布。

2. 价格跨度大

价格从**17元**（小吃快餐）到**1450元**（高端海鲜）分布广泛，能较好地反映杭州餐饮市场的多样性。

3. 品类覆盖广

数据覆盖了**浙菜、川菜、湘菜、粤菜、徽菜、日料、西餐、火锅、烧烤、咖啡奶茶**等几乎所有主流品类，为后续的品类分析提供了充足样本。

4. 多源数据融合

从数据中可以看到，`rating` 和 `cost` 字段已成功补充，说明你的详情API补充程序运行正常。缺失值很少（如部分记录 `cost` 为空），整体质量很高。

三、仍存在的少量问题与建议

1. 少量价格缺失

- 例如：“粤江南(杭州店)”的 `cost` 显示为 `[]`，有约5-10条类似记录。
- **建议**：对于建模，可直接删除这些记录（占比<1%，影响极小）。

2. 部分商家分类不纯

- 个别记录的 `type` 包含多个分类（如“餐饮服务;中餐厅;浙江菜|生活服务;美容美发店;美容美发店”），存在跨类情况。
- **建议**：提取第一个分号前的一级分类 `category_l1` 即可满足多数分析需求。

3. 数据去重检查

- 虽然采集时已做去重，但建议最终确认一次：按 `id` 去重后，数据量预计在**2200+条**，仍然充足。

四、数据质量统计（估算）

指标	数值	评估
总记录数	~2300+	✔ 优秀
评分覆盖率	>99%	✔ 优秀
价格覆盖率	>98%	✔ 优秀
经纬度完整率	100%	✔ 优秀
分类字段完整率	100%	✔ 优秀
重复率	<1%	✔ 优秀

五、后续行动建议

步骤1：数据清洗（15分钟）

```
python

import pandas as pd
import numpy as np

df = pd.read_csv("hangzhou_catering_combined.csv", encoding="utf-8-sig")

# 1. 按id去重
df = df.drop_duplicates(subset=['id'], keep='first')

# 2. 处理缺失值（删除少量评分或价格为空的记录）
df['rating'] = pd.to_numeric(df['rating'], errors='coerce')
df['cost'] = pd.to_numeric(df['cost'], errors='coerce')
df = df.dropna(subset=['rating', 'cost'])

# 3. 拆分分类（保留一级、二级分类）
df['category_l1'] = df['type'].str.split(';').str[0]
df['category_l2'] = df['type'].str.split(';').str[1]

# 4. 拆分经纬度
df['longitude'] = df['location'].str.split(',').str[0].astype(float)
df['latitude'] = df['location'].str.split(',').str[1].astype(float)
```

```
# 5. 提取行政区 (已有adname, 可直接使用)
df['district'] = df['adname']

# 6. 保存清洗后的数据
df.to_csv("hangzhou_catering_final.csv", index=False, encoding="utf-8-sig")
print(f"清洗完成, 剩余 {len(df)} 条记录")
```

步骤2：探索性数据分析

- 绘制评分分布直方图、价格箱线图
- 按品类统计平均评分和价格
- 按行政区统计商家数量和评分均值

步骤3：评分预测模型构建

有了2300+条完整数据，可以开始构建模型了：

- **目标变量：** rating
- **特征：** cost 、 category_l1 、 category_l2 、 district 、 longitude 、 latitude 、 atag
(提取标签数量或关键词)
- **模型选择：** 线性回归、随机森林、XGBoost等
- **评估：** MSE、 R^2

六、结论

这份数据已经达到了项目要求的“优质数据”标准。它具备：

- ☒ 足够的样本量 (2300+)
- ☒ 完整的目标变量 (评分)
- ☒ 丰富的特征 (价格、分类、地理位置、标签)
- ☒ 良好的数据质量 (缺失率低)

你可以基于这份数据：

1. **立即开始数据清洗和建模工作**
2. **在Web平台的数据源管理页面中展示这份数据的质量指标**

3. 后续如有需要，可继续按此方法扩展其他城市或品类

恭喜你完成了数据采集阶段的核心工作！接下来可以进入**数据清洗、特征工程和模型构建**阶段。如果需要我帮你设计评分预测模型的代码框架，随时告诉我。